Inteligência Artificial Probabilistica - Projeto Final

Duração: 3 aulas PL

Entrega:
- Entrega final: **08/05/2025**

Descrição:
O projeto tem como principal objetivo estender os conhecimentos adquiridos na disciplina. O trabalho pode ser desenvolvido individualmente ou em grupos de 2 elementos.

Contexto:
O objetivo deste projeto é desenvolver um sistema de previsão probabilística para resultados de jogos de futebol da liga portuguesa, e respetiva aplicação à análise de um mercado de apostas desportivas. Através de técnicas de modelagem probabilística, quantificação de incerteza e teoria de utilidade, pretende-se construir modelos que permitam prever resultados de jogos e avaliar a sua utilidade comparando as probabilidades previstas com as odds do respetivo jogo. O projeto abrange a construção de Redes Bayesianas (com aprendizagem de estrutura e parâmetros), classificadores probabilísticos com quantificação de incerteza, e técnicas de avaliação de calibração e utilidade.

Datasets:
Será utilizado um conjunto de dados relacionado com resultados de jogos da liga portuguesa de futebol. Os dados estão acessíveis em:

- https://github.com/vcerqueira/teaching-probabilistic-ai/tree/main/project/dataset (dataset.csv)

Cada observação do dataset corresponde a um jogo e inclui as seguintes informações:

- **date:** Data do jogo
- **ht:** Equipa da casa
- **at:** Equipa de fora
- **hg:** Golos marcados pela equipa da casa
- **ag:** Golos marcados pela equipa de fora
- **result:** Resultado do jogo (H: ganha equipa da casa, D: empate, A: ganha equipa de fora)
- **h_odds:** Odd para o resultado H
- **d_odds:** Odd para o resultado D
- **a_odds**: Odd para o resultado A
- **ht_form_points:** Número de pontos nos últimos 5 jogos para a equipa da casa
- **ht_form_goals_scored:** Golos marcados nos últimos 5 jogos pela equipa da casa

- **ht_form_goals_conceded:** Golos sofridos nos últimos 5 jogos pela equipa da casa
- **ht_form_wins:** Número de vitórias nos últimos 5 jogos pela equipa da casa
- **at_form_points:** Número de pontos nos últimos 5 jogos para a equipa de fora
- **at_form_goals_scored:** Golos marcados nos últimos 5 jogos pela equipa de fora
- **at_form_goals_conceded:** Golos sofridos nos últimos 5 jogos pela equipa de fora
- **at_form_wins:** Número de vitórias nos últimos 5 jogos pela equipa de fora
- **ht_home_form_points:** Número de pontos nos últimos 5 jogos para a equipa da casa a jogar em casa
- **ht_home_form_goals_scored:** Número de golos marcados nos últimos 5 jogos para a equipa da casa a jogar em casa
- **at_away_form_points:** Número de pontos nos últimos 5 jogos para a equipa de fora a jogar fora
- **at_away_form_goals_scored:** Número de golos marcados nos últimos 5 jogos para a equipa de fora a jogar fora
- **h2h_home_wins:** Em frente-a-frente, número de vitórias para a equipa da casa
- **h2h_draws:** Em frente-a-frente, número de empates
- **h2h_away_wins:** Em frente-a-frente, número de vitórias para a equipa de fora
- **ht_form:** Variável ht_form_points discretizada
- **at_form:** Variável at_form_points discretizada
- **ht_attack:** Variável ht_form_goals_scored discretizada
- **at_attack:** Variável at_form_goals_scored discretizada
- **joint_attack:** Variáveis ht_attack e at_attack concatenadas
- **h2h_dominance:** Variáveis h2h* discretizadas
- **odds_favorite:** Variáveis h_odds, d_odds, a_odds discretizadas

Plano de trabalho:

PARTE 1: Redes Bayesianas

1. Construção da estrutura da Rede Bayesiana para o domínio do futebol, utilizando as variáveis discretizadas. Avaliar estratégias de construção incluindo Knowledge Engineering (estrutura manual baseada em conhecimento do domínio) e aprendizagem automática de estrutura.
2. Análise da Rede Bayesiana utilizando D-separação para identificar independências condicionais entre variáveis.
3. Aprendizagem dos parâmetros da Rede Bayesiana. Estimação das distribuições condicionais (CPTs) com base nos dados observados. Comparação entre abordagens: Maximum Likelihood Estimation (MLE) e estimação Bayesiana.
4. Realização de inferências probabilísticas. Demonstração da utilização da rede para responder a queries relevantes.

Exemplo de inferências que podem ser realizadas:

- Qual a probabilidade de vitória da equipa da casa, dado que tem boa forma recente e é favorita nas odds?
- Como muda a probabilidade de empate quando ambas as equipas têm forma média?
- Qual o resultado mais provável dado o histórico de confrontos diretos?

PARTE 2: Classificação Probabilística e Quantificação de Incerteza

1. Treinar e avaliar um classificador probabilístico Naive Bayes para prever o resultado dos jogos (H/D/A).
2. Aplicar Conformal Prediction ao classificador Naive Bayes. Comparar os conjuntos de previsão (prediction sets) e avaliar a cobertura obtida.
3. Avaliar a calibração dos modelos utilizando Reliability Diagrams e métricas como Brier Score e Log Loss.
4. Otimizar os hiperparâmetros de um algoritmo de aprendizagem (e.g., Naive Bayes, Logistic Regression) utilizando Bayesian Optimization.

PARTE 3: Teoria de Utilidade e Tomada de Decisão

1. Avaliar a utilidade dos modelos treinados comparando as probabilidades previstas com as odds do respetivo jogo. Identificar situações onde o modelo discorda significativamente das odds.
2. Implementar uma estratégia de Reject Option baseada na quantificação de incerteza. Avaliar o impacto na performance preditiva quando o modelo se abstém de prever em casos de alta incerteza. Decidir quando o modelo deve deferir para as odds do respetivo jogo, em vez de usar as suas próprias previsões, para maximizar o desempenho preditivo.

PARTE 4: Preparação de relatório

1. Preparação de relatório que descreva o trabalho realizado, os resultados obtidos, assim como uma análise crítica dos mesmos.
2. Deve ser entregue o relatório no formato PDF, assim como todo o código e dados processados, preferencialmente em Python e Jupyter Notebook. A extensão do relatório deve ter no máximo 20 páginas (excluindo anexos e código)