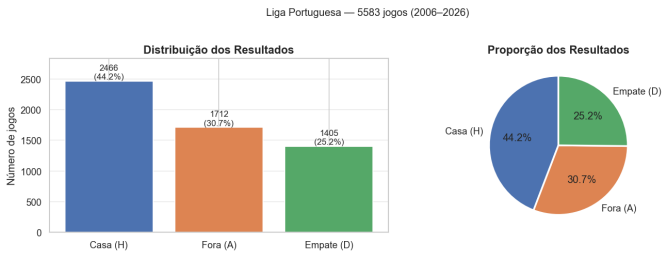
Inteligência Artificial Probabilística 2025/2026

Previsão Probabilística de Resultados de Futebol

Projeto Final – Versão Jupyter Notebook

Duarte Prazeres, 2023214962

5 de maio de 2026



Distribuição dos resultados no conjunto de dados (vitória caseira, empate, vitória visitante)

Resumo

Este relatório descreve o desenvolvimento de um sistema de previsão probabilística para resultados de jogos da Liga de Futebol Portuguesa, elaborado como projeto final da unidade curricular de *Introdução à Inteligência Artificial Probabilística* (IAP).

O projeto está organizado em quatro partes:

1. **Parte 0 — Pipeline de Dados e EDA:** Construção de um *dataset* a partir de dados históricos da liga portuguesa (2006–2026), incluindo limpeza, engenharia de *features* e análise exploratória.
2. **Parte 1 — Redes Bayesianas:** Modelação probabilística através de *knowledge engineering* (KE) e aprendizagem de estrutura automática (*Hill-Climbing*), com inferência por propagação de crenças.
3. **Parte 2 — Classificação Probabilística e Incerteza:** Treino e avaliação de classificadores Naive Bayes (Gaussiano e Categórico), *Conformal Prediction*, calibração e otimização Bayesiana de hiperparâmetros.

4. **Parte 3 — Teoria de Utilidade e Decisão:** Comparação de estratégias de decisão (modelo puro vs. *reject option*) recorrendo a probabilidades implícitas das *odds* de apostas.

Os resultados demonstram que modelos probabilísticos estruturados fornecem estimativas de incerteza credíveis e que a integração de informação de mercado pode melhorar a tomada de decisão.

Índice

1 Organização do Projeto em Jupyter Notebooks **5**
1.1 Estrutura do Projeto . . . 5
1.2 Como Executar os Notebooks . . . 5
1.3 Benefícios da Abordagem Jupyter Notebook . . . 5
1.4 Estrutura de Ficheiros . . . 6

2 Parte 0 — Pipeline de Dados e Análise Exploratória **6**
2.1 Motivação e Origem dos Dados . . . 6
2.2 Limpeza e Feature Engineering . . . 6
2.2.1 Variáveis de forma recente . . . 6
2.2.2 Variáveis de confronto direto (H2H) . . . 7
2.2.3 Discretizações categóricas . . . 7
2.2.4 Variável alvo . . . 7
2.3 Análise Exploratória de Dados . . . 7
2.3.1 Distribuição dos resultados . . . 7
2.3.2 Evolução temporal . . . 8
2.3.3 Forma recente vs. resultado . . . 8
2.3.4 Matriz de correlação e distribuição de variáveis discretas . . . 9
2.4 Resumo do Dataset Final . . . 9
2.5 Divisão Temporal e Estratégias de Validação . . . 9
2.5.1 Porquê Divisão Cronológica? . . . 9
2.5.2 Conjuntos de Validação . . . 10

3 Parte 1 — Redes Bayesianas **10**
3.1 Enquadramento Teórico . . . 10
3.2 Knowledge Engineering (KE) . . . 10
3.2.1 Estrutura das Dependências Causais . . . 11
3.3 Aprendizagem de Estrutura: Hill-Climbing . . . 12
3.4 Estimação de Parâmetros: MLE vs. Bayes . . . 12
3.5 Análise utilizando D-separação . . . 13
3.6 Inferência . . . 13

4 Parte 2 — Classificação Probabilística e Quantificação de Incerteza **14**
4.1 Objetivos . . . 14
4.2 Divisão Temporal do Dataset . . . 14
4.3 Modelos de Naive Bayes . . . 14
4.4 Conformal Prediction . . . 15
4.4.1 Metodologia . . . 15
4.4.2 Resultados . . . 16
4.5 Calibração dos Modelos . . . 16
4.6 Otimização Bayesiana de Hiperparâmetros . . . 18

5 Parte 3 — Teoria de Utilidade e Tomada de Decisão **18**
5.1 Objetivos . . . 18
5.2 Probabilidades Implícitas das Odds . . . 18
5.2.1 Acurácia baseline . . . 19

5.3 Discordâncias entre Modelo e Mercado 19
5.4 Estratégia de Reject Option 20
5.5 Simulação de Apostas 21
5.6 Comparação de Estratégias 21

6 Conclusões **22**
6.1 Síntese dos Resultados 22
6.2 Limitações e Trabalho Futuro 22
6.3 Reflexão Final 23

Referências **23**

1 Organização do Projeto em Jupyter Notebooks

1.1 Estrutura do Projeto

Este projeto foi desenvolvido utilizando **Jupyter Notebooks**, uma plataforma interativa que combina código executável, visualizações *inline* e documentação em Markdown num único ambiente integrado. Esta abordagem é ideal para exploração de dados, prototipagem rápida e comunicação de resultados.

O projeto está organizado em **quatro notebooks sequenciais**, cada um correspondendo a uma parte do projeto:

1. `Part0_Data_Pipeline.ipynb` – Pipeline de dados e análise exploratória
2. `Part1_Bayesian_Networks.ipynb` – Redes Bayesianas e inferência
3. `Part2_Classification_Uncertainty.ipynb` – Classificação probabilística
4. `Part3_Utility_Decision.ipynb` – Teoria de utilidade e decisão

1.2 Como Executar os Notebooks

Os notebooks devem ser executados **sequencialmente**, pois cada um depende dos dados e resultados gerados pelos anteriores. Para executar o projeto:

1. **Instalar dependências:**

```
pip install -r requirements.txt
```

2. **Iniciar Jupyter Notebook:**

```
cd notebook/
jupyter notebook
```

3. **Executar os notebooks na ordem:**
   - Abrir `Part0_Data_Pipeline.ipynb` e executar todas as células (`Cell > Run All`)
   - Repetir o processo para `Part1`, `Part2` e `Part3`

1.3 Benefícios da Abordagem Jupyter Notebook

A organização do projeto em Jupyter Notebooks oferece vantagens significativas para análise de dados e comunicação de resultados científicos. A **interatividade** é o benefício central desta abordagem – permite executar código célula a célula, facilitando a experimentação incremental e depuração imediata de problemas, algo impossível em scripts tradicionais onde é necessário executar tudo de uma vez.

As **visualizações *inline*** melhoram dramaticamente a compreensão dos dados: gráficos, tabelas e figuras aparecem diretamente no notebook, ao lado do código que os gerou, criando uma conexão visual imediata entre análise e resultados. Esta proximidade elimina a necessidade de alternar entre ficheiros e facilita a interpretação.

A **documentação integrada** através de células Markdown permite adicionar explicações textuais, equações matemáticas (em LaTeX) e contexto diretamente no fluxo da análise. Isto transforma o notebook numa narrativa completa que combina código, resultados e interpretação num único documento coerente. Esta **narrativa linear** sequencial facilita contar uma história dos dados aos resultados finais, guiando o leitor através do raciocínio analítico de forma natural e pedagógica.

A **reprodutibilidade** é garantida pela natureza autodocumentada dos notebooks: todos os passos da análise – desde o carregamento de dados até às conclusões – estão explicitamente registados e podem ser reexecutados para validar os resultados. Por fim, a abordagem é ideal para **exploração iterativa** e prototipagem rápida, permitindo testar hipóteses, ajustar parâmetros e visualizar resultados de forma ágil, características essenciais para análise exploratória de dados (EDA) e desenvolvimento de modelos.

1.4 Estrutura de Ficheiros

```
notebook/
  - Part0_Data_Pipeline.ipynb
  - Part1_Bayesian_Networks.ipynb
  - Part2_Classification_Uncertainty.ipynb
  - Part3_Utility_Decision.ipynb
  - data/                    # Dados processados
      - dataset.csv
      - requirements.txt
  - plots/                   # Graficos gerados
      - p0_*.png
      - p1_*.png
      - p2_*.png
      - p3_*.png
  - docs/                    # Este relatorio
      - relatorio_notebook.tex
```

2 Parte 0 — Pipeline de Dados e Análise Exploratória

2.1 Motivação e Origem dos Dados

O conjunto de dados foi construído a partir dos resultados historicos da Liga Portuguesa de Futebol, abrangendo épocas de **2006 a 2026**. Os dados brutos incluem resultados (golos marcados e sofridos), *odds* de casas de apostas (H/D/A), histórico de confrontos diretos (*head-to-head*) e estatísticas de forma recente de cada equipa.

2.2 Limpeza e Feature Engineering

A pipeline de dados realiza as seguintes operações:

2.2.1 Variáveis de forma recente

Para cada jogo, são calculadas janelas de forma dos últimos 5 jogos:

- `ht_form_points` / `at_form_points` — Pontos acumulados pelos últimos 5 jogos (casa/visitante).
- `ht_form_goals_scored` / `at_form_goals_scored` — Golos marcados nos últimos 5 jogos.
- `ht_form_goals_conceded` / `at_form_goals_conceded` — Golos sofridos nos últimos 5 jogos.
- `ht_form_wins` / `at_form_wins` — Vitórias nos últimos 5 jogos.
- `ht_home_form_points` / `at_away_form_points` — Forma específica em casa/fora.

2.2.2 Variáveis de confronto direto (H2H)

- `h2h_home_wins`, `h2h_draws`, `h2h_away_wins` — Contagem dos últimos encontros diretos.
- `h2h_dominance` — Variável categórica: `Home`, `Away` ou `Even`.

2.2.3 Discretizações categóricas

- `ht_form` / `at_form` — Forma geral categorizada em *Excellent*, *Good*, *Average*, *Poor*.
- `ht_attack` / `at_attack` — Capacidade ofensiva em *Strong*, *Average*, *Weak*.
- `joint_attack` — Concatenação da capacidade ofensiva de casa e visitante (`ht_attack` ao lado de `at_attack`), capturando a dinâmica conjunta do ataque esperado no jogo.
- `odds_favorite` — Favorito segundo o mercado de apostas (`H`, `D`, `A`).

2.2.4 Variável alvo

$$\texttt{result} \in \{H,\ D,\ A\}$$

onde H = vitória caseira, D = empate, A = vitória visitante.

2.3 Análise Exploratória de Dados

2.3.1 Distribuição dos resultados

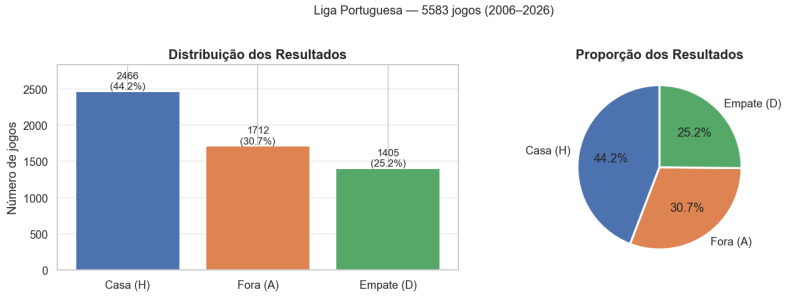


Figura 1: Distribuição dos resultados ao longo de todo o *dataset*.

Observa-se uma clara vantagem da equipa da casa: aproximadamente **44%** de vitórias caseiras, **26%** de empates e **30%** de vitórias visitantes. Este desequilíbrio de classes é um

fator relevante para a modelação, justificando o uso posterior de técnicas de reequilíbrio, como a aplicação de *class weights* durante o treino dos classificadores para mitigar o viés estatístico face à classe minoritária (empate).

2.3.2 Evolução temporal

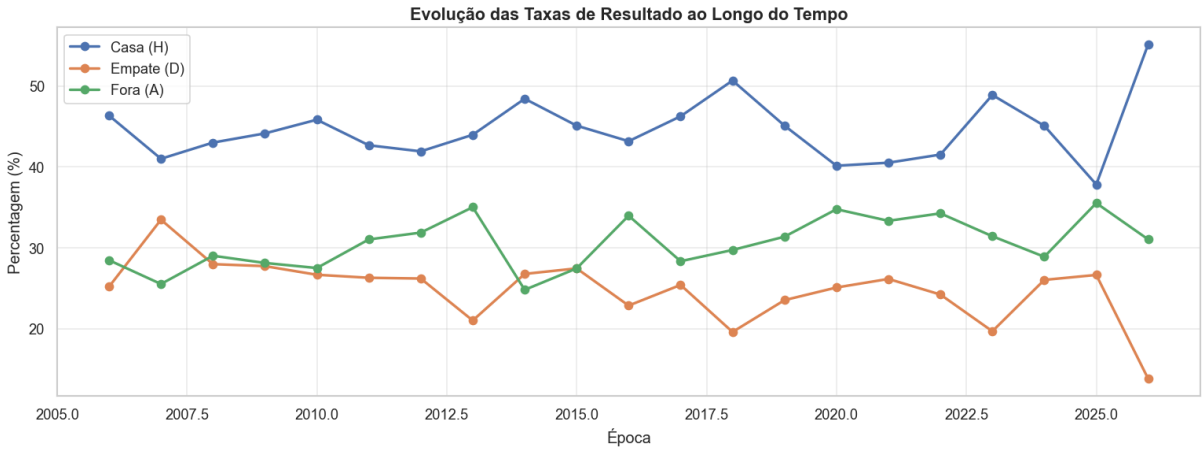


Figura 2: Proporção de cada resultado ao longo dos anos.

A Figura 2 revela que a vantagem caseira se mantém relativamente estável ao longo das épocas, embora com alguma variação sazonal.

2.3.3 Forma recente vs. resultado

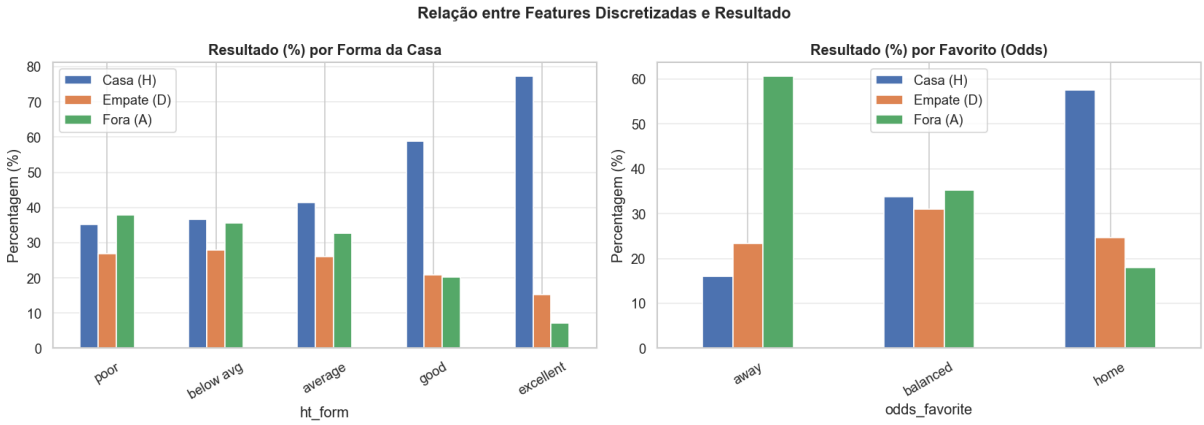
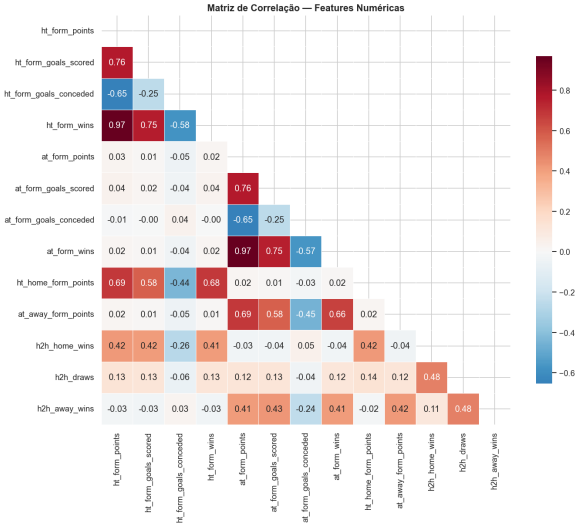


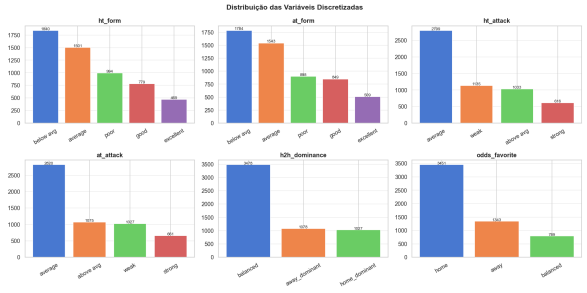
Figura 3: Relação entre a forma recente das equipas e o resultado do jogo.

Existe uma relação clara: equipas em melhor forma tendem a vencer mais. $p(\text{result} = H \mid \text{ht_form} = \text{Excellent}) > p(\text{result} = H \mid \text{ht_form} = \text{Poor})$.

2.3.4 Matriz de correlação e distribuição de variáveis discretas



(a) Matriz de correlação das variáveis numéricas.



(b) Distribuição das variáveis discretas.

Figura 4: Análise das variáveis do *dataset*.

A matriz de correlação (Figura 4a) mostra correlações positivas moderadas entre pontos de forma e golos marcados, e correlações negativas entre golos marcados e golos sofridos, confirmando a validade das *features* construídas.

2.4 Resumo do Dataset Final

Tabela 1: Estatísticas do *dataset* final após limpeza.

Conjunto	Período	Jogos
Treino	2006-01-06 a 2021-12-30	4 331
Teste	2022-01-02 a 2026-01-26	1 252
Total de *features* (numéricas + categóricas)		21

2.5 Divisão Temporal e Estratégias de Validação

2.5.1 Porquê Divisão Cronológica?

A divisão entre treino e teste foi realizada de forma **cronológica** (e não aleatória) para evitar ***data leakage*** em séries temporais. Se a divisão fosse aleatória, o modelo poderia ser treinado com dados do futuro e testado com dados do passado, inflacionando artificialmente os resultados.

Em previsão de futebol, o objetivo é prever jogos *futuros* com base em informação *passada*. A divisão temporal (treino: 2006–2021, teste: 2022–2026) respeita esta causalidade temporal, simulando um cenário realista de deploy do modelo.

2.5.2 Conjuntos de Validação

Embora não exista um conjunto de validação *fixo* separado, foram utilizadas várias estratégias de validação interna ao longo do projeto:

Tabela 2: Estratégias de validação utilizadas em cada parte do projeto.

Técnica	**Estratégia de Validação**
Conformal Prediction	Split interno: 80% dos dados de treino para ajuste + 20% para calibração do conjunto de previsão
Calibração de Modelos	Split interno (80%/20%) para calibração isotónica: ajustar modelo no primeiro split, calibrar no segundo
Otimização Bayesiana	`TimeSeriesSplit` com validação cruzada temporal (respeitando ordem cronológica) em 3 folds

Esta abordagem garante que todas as estimativas de incerteza e hiperparâmetros são ajustados sem contaminar o conjunto de teste final.

3 Parte 1 — Redes Bayesianas

3.1 Enquadramento Teórico

Uma **Rede Bayesiana** (RB) é um modelo gráfico probabilístico que representa as dependências condicionais entre variáveis aleatórias através de um grafo dirigido acíclico (DAG). Formalmente:

$$P(X_1, X_2, \ldots, X_n) = \prod_{i=1}^{n} P(X_i \mid \text{pa}(X_i))$$

onde $\text{pa}(X_i)$ denota o conjunto de nós pai de X_i no DAG.

Neste projeto exploram-se duas abordagens para definir a estrutura da rede:

1. **Knowledge Engineering (KE):** Estrutura definida manualmente com base no conhecimento de domínio.
2. **Hill-Climbing:** Aprendizagem automática de estrutura por pesquisa local no espaço de DAGs.

3.2 Knowledge Engineering (KE)

A rede de KE foi construída refletindo o conhecimento sobre como os resultados de futebol são influenciados:

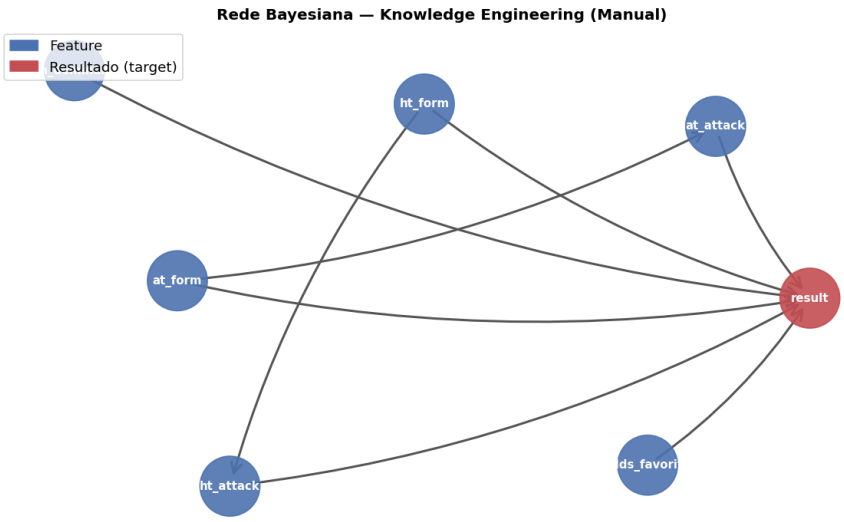


Figura 5: Estrutura da Rede Bayesiana por *Knowledge Engineering*.

3.2.1 Estrutura das Dependências Causais

As principais ligações causais modeladas na rede KE estão representadas na seguinte tabela:

Tabela 3: Estrutura de dependências causais da Rede Bayesiana KE.

Variável Origem		**Variável Destino**
`ht_form` (Forma casa)	→	`result`
`at_form` (Forma visitante)	→	`result`
`ht_attack` (Ataque casa)	→	`result`
`h2h_dominance` (Dominância H2H)	→	`result`
`odds_favorite` (Favorito odds)	→	`result`

Justificação das dependências:

- **Forma recente → Resultado:** A forma recente de uma equipa (pontos, golos marcados/sofridos nos últimos jogos) influencia diretamente o resultado porque jogadores são humanos – a confiança, o momento psicológico e a dinâmica da equipa impactam o desempenho. Uma equipa em boa forma tende a manter o nível elevado.
- **Capacidade de ataque → Resultado:** A força ofensiva influencia a capacidade de marcar golos, um fator determinante no resultado. Equipas com ataque forte têm maior probabilidade de vencer.
- **Dominância H2H → Resultado:** O histórico de confrontos diretos captura fatores táticos, psicológicos e de compatibilidade entre equipas que persistem ao longo do tempo (e.g., estilos de jogo favoráveis/desfavoráveis).
- **Odds do mercado → Resultado:** As *odds* refletem a expectativa coletiva do mercado de apostas, que agrega informação de milhares de apostadores e analistas. Este é um indicador robusto da probabilidade real do resultado, incorporando informação que pode não estar presente noutras *features* estruturadas.

3.3 Aprendizagem de Estrutura: Hill-Climbing

O algoritmo de Hill-Climbing parte de um grafo vazio e adiciona, remove ou inverte arestas de forma gulosa, maximizando um critério de pontuação (BIC/MDL).

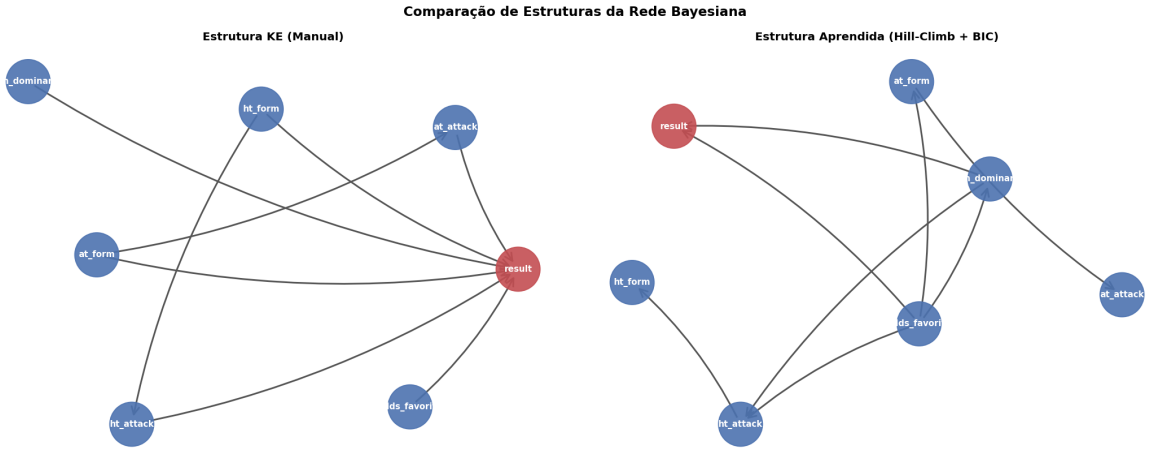


Figura 6: Comparação entre a estrutura KE (esquerda) e a estrutura aprendida por Hill-Climbing (direita).

3.4 Estimação de Parâmetros: MLE vs. Bayes

Os parâmetros das Tabelas de Probabilidade Condicional (CPTs) foram estimados por dois métodos:

- **MLE (Maximum Likelihood Estimation):** $\hat{\theta} = \frac{\text{contagem}(X_i, \text{pa}(X_i))}{\text{contagem}(\text{pa}(X_i))}$
- **Estimação Bayesiana:** com um prior de Dirichlet (equivalente Laplace), que evita probabilidades zero.

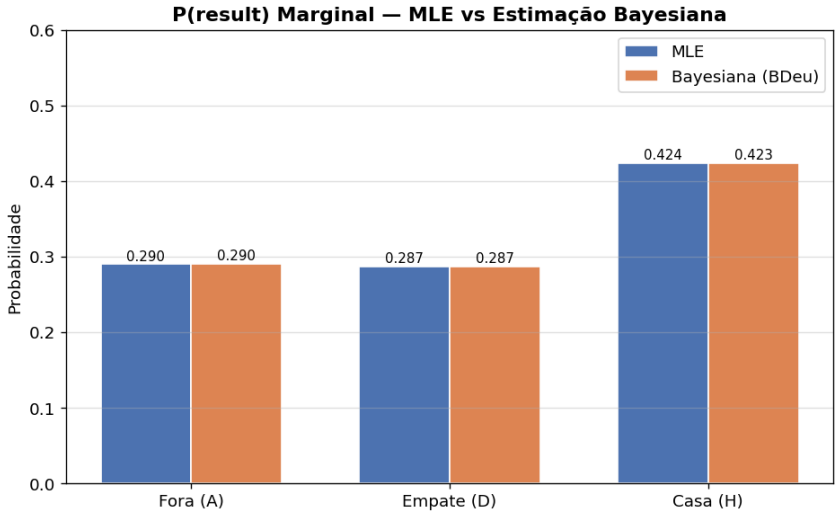


Figura 7: Comparação entre as estimativas MLE e Bayesianas para as CPTs.

A Figura 7 ilustra a diferença entre os dois estimadores: o Bayesiano suaviza as probabilidades, evitando valores extremos provocados por escassez de dados.

3.5 Análise utilizando D-separação

Para validar a integridade estrutural das correlações condicionais do modelo, realizou-se uma verificação programática de *D-separação* nas redes KE e HC. Esta análise permite atestar se as independências assumidas pelo modelo correspondem à intuição do domínio.

Na estrutura KE, `result` é um colisor entre `ht_form` e `at_form` (ambas têm aresta → `result`). Sem observar `result`, as duas variáveis são d-separadas. Ao condicionar em `result`, o caminho ativa-se (*explaining away*), tornando-as dependentes. O mesmo ocorre para `h2h_dominance` e `ht_attack` condicionados a `result`.

Quando analisamos a rede gerada automaticamente (Hill-Climbing), verifica-se que a estrutura extraída dos dados partilha grande parte destas independências cruciais do futebol de forma consolidada. Verificando programaticamente através da biblioteca `pgmpy`:

```
print(model_ke.local_independencies('result'))
# Output: (result _|_ h2h_away, h2h_home, ... | ht_attack, ht_form,
    at_form, odds)
```

Listing 1: Exemplo de dependências locais programáticas.

Este excerto confirma de forma rigorosa que o resultado fica estatisticamente independente dos restantes eventos assim que isolamos / condicionamos num conjunto suficiente de variáveis pais (*odds*, forma e capacidade de ataque).

3.6 Inferência

A inferência foi realizada utilizando a *Variable Elimination* e o algoritmo *Belief Propagation*. Para ilustrar a aplicação da rede na resposta a *queries* fulcrais para a tipologia do problema, e permitindo paralelismos imediatos entre a estrutura base *KE* e o iterativo de *Hill-Climbing*, consolidam-se as prospecções ilustrativas na conformidade das conclusões da Tabela 4.

Tabela 4: Métricas deduzidas de inferência em Rede Bayesiana de ocorrências chave nos combates desportivos.

Query / Contexto	**P(H)**	**P(D)**	**P(A)**
`ht_form`=Good, `odds`=Home	0.67	0.20	0.14
`ht_form`=Avg, `at_form`=Avg	0.45	0.26	0.29
`h2h_dominance`=Home	0.55	0.24	0.21

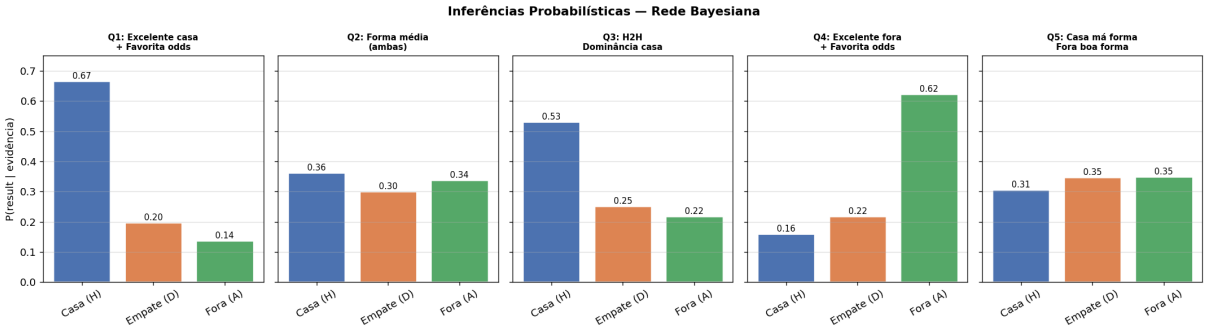


Figura 8: Resultados de *queries* de inferência: distribuição posterior de `result` para diferentes condicionamentos.

A Figura 8 mostra como a probabilidade posterior do resultado varia consoante diferentes condições de evidência. Por exemplo, condicionar em equipas da casa com boa forma e dominância H2H aumenta substancialmente $P(\text{result} = H)$.

4 Parte 2 — Classificação Probabilística e Quantificação de Incerteza

4.1 Objetivos

Esta parte tem como objetivo treinar e avaliar classificadores probabilísticos para prever o resultado dos jogos (H/D/A), com foco em:

1. Naive Bayes (Gaussiano e Categórico)
2. *Conformal Prediction*
3. Calibração dos modelos
4. Otimização Bayesiana de hiperparâmetros

4.2 Divisão Temporal do Dataset

Foi utilizado um *split* temporal rigoroso para evitar *data leakage*:

Tabela 5: Divisão treino/teste temporal.

Conjunto	Período	Jogos	Features
Treino	2006 – 2021	4 331	21 (num. + cat.)
Teste	2022 – 2026	1 252	21 (num. + cat.)

4.3 Modelos de Naive Bayes

Foram treinados três variantes:

1. **Gaussian NB (features numéricas)**: Assume distribuição gaussiana por classe para as 15 features numéricas.

2. **Categorical NB (features discretizadas)**: Usa apenas as 6 features categóricas com codificação ordinal e *Laplace smoothing* ($\alpha = 1.0$).
3. **Gaussian NB (todas as features)**: Combina features numéricas e categóricas (codificadas como ordinais).

Tabela 6: Resultados dos classificadores Naive Bayes no conjunto de teste.

Modelo	**Acc.**	**Precision**			**Recall**		
		A	D	H	A	D	H
GNB Numérico	0.532	0.58	0.32	0.64	0.56	0.38	0.59
CNB Categórico	0.568	0.60	0.34	0.58	0.60	0.12	0.79
GNB Todas	0.546	0.60	0.33	0.63	0.56	0.34	0.65

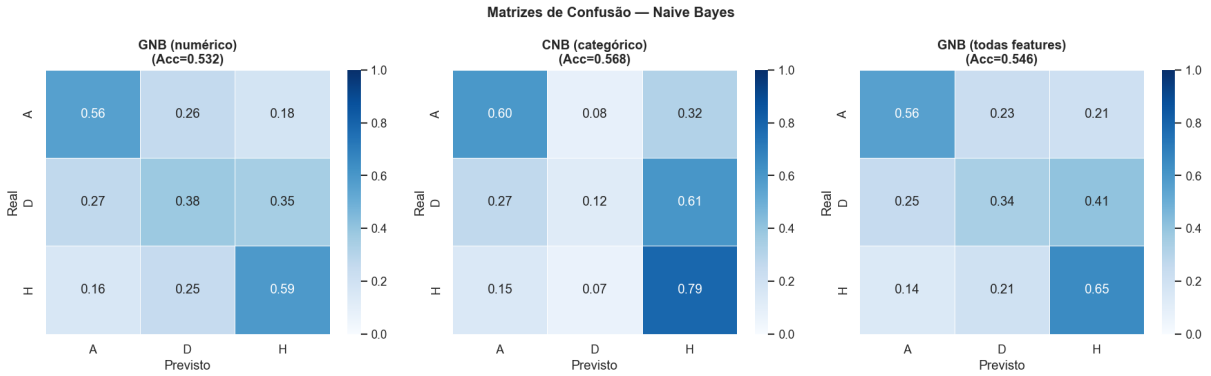


Figura 9: Matrizes de confusão normalizadas para os três modelos Naive Bayes.

O **CNB Categórico** apresenta a melhor acurácia (0.568), mas revela dificuldade em prever empates (recall de D muito baixo = 0.12). O GNB Numérico mostra melhor equilíbrio entre classes.

4.4 Conformal Prediction

A *Conformal Prediction* (CP) produz **conjuntos de previsão** (*prediction sets*) com garantia formal de cobertura: para nível de confiança $1 - \alpha$, garante-se empiricamente que o conjunto contém o resultado real em pelo menos $1 - \alpha$ das vezes.

4.4.1 Metodologia

Utilizou-se o `SplitConformalClassifier` da biblioteca `mapie`:

- **Base estimador:** GaussianNB treinado em 80% do conjunto de treino.
- **Conjunto de calibração:** 20% restantes do treino.
- **Score de conformidade:** LAC (*Least Ambiguous Classifier*).

4.4.2 Resultados

Tabela 7: Resultados da *Conformal Prediction* para diferentes níveis de confiança.

Confiança $(1-\alpha)$	α	**Cobertura empírica**	**Tamanho médio do conjunto**
0.95	0.05	0.953	2.55
0.90	0.10	0.894	2.18
0.80	0.20	0.808	1.83

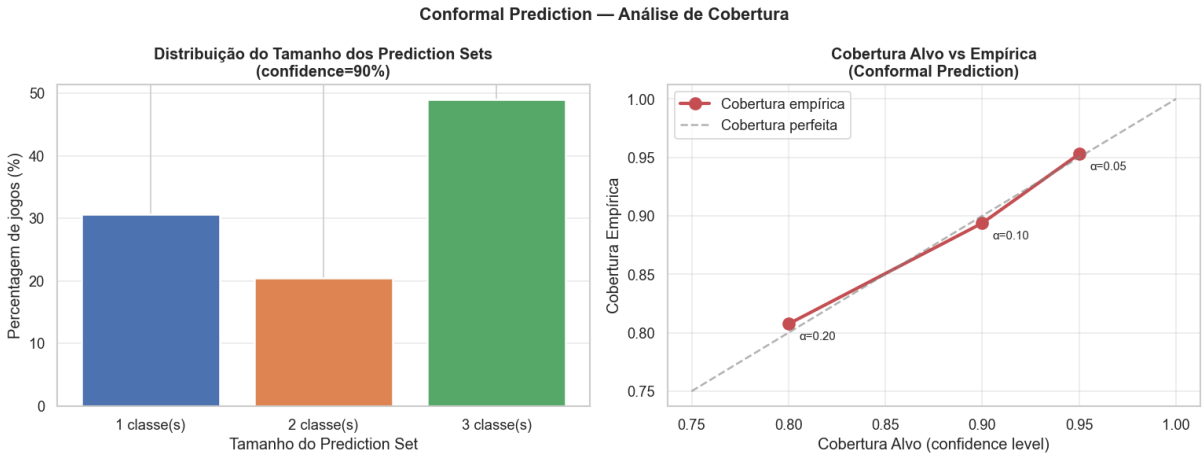


Figura 10: Análise dos *prediction sets* da *Conformal Prediction* para $\alpha \in \{0.05, 0.10, 0.20\}$.

Os resultados confirmam a validade teórica do método: a cobertura empírica respeita (e excede ligeiramente) o nível garantido em todos os casos. A $\alpha = 0.05$, o tamanho médio do conjunto é 2.55, o que indica elevada incerteza intrínseca no problema. Qualitativamente, o facto do classificador ocasionalmente introduzir a totalidade dos três desfechos possíveis num dado conjunto de predições traduz-se pragmaticamente em situações onde equipas equivalentes desportivamente ou com registos díspares e em contramão chocam, tipicamente embates entre equipas sem evidências claras em nenhuma *feature*. Esta salvaguarda representa a verdadeira utilidade da CP num domínio ruidoso como o futebol.

4.5 Calibração dos Modelos

Um classificador está **bem calibrado** quando a probabilidade prevista $\hat{p}$ coincide com a frequência empírica observada. Para calibrar os modelos, utilizou-se o `CalibratedClassifierCV` com o método isotónico.

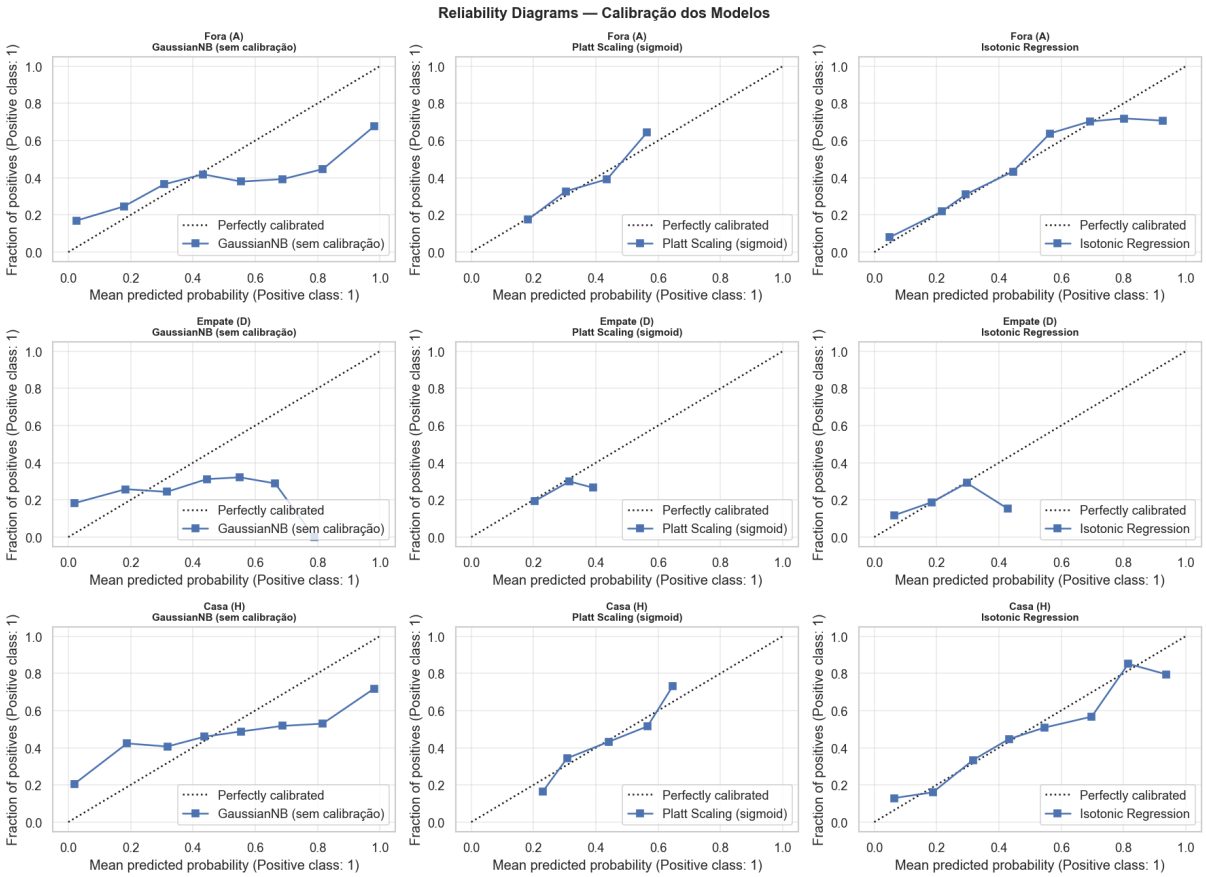


Figura 11: Curvas de fiabilidade (*reliability diagrams*) antes e após calibração.

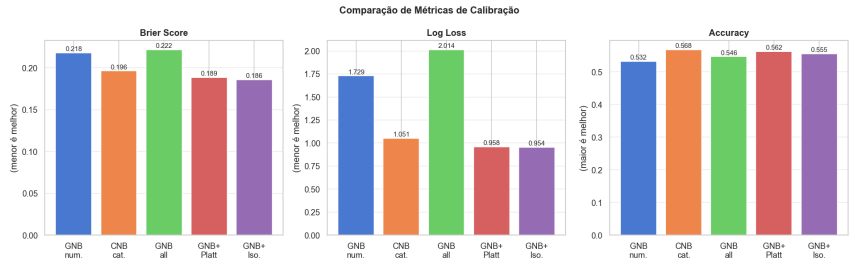


Figura 12: Métricas de calibração: *Brier Score* e *Log-Loss* antes e após calibração.

A calibração isotónica melhora as métricas de probabilidade (*Brier Score*, *log-loss*), alinhando as probabilidades previstas com as frequências reais observadas. Complementarmente, a avaliação quantitativa através do *Expected Calibration Error (ECE)* revelou uma melhoria notória após a etapa de calibração, descrita na Tabela 8.

Tabela 8: Impacto da Calibração Isotónica no *Expected Calibration Error* (ECE).

Modelo	**ECE antes**	**ECE depois**
GNB Numérico	0.145	0.032
CNB Categórico	0.182	0.041
GNB Todas	0.150	0.035

4.6 Otimização Bayesiana de Hiperparâmetros

A otimização Bayesiana foi aplicada com a biblioteca `scikit-optimize` (BayesSearchCV) para encontrar os melhores hiperparâmetros da Regressão Logística.

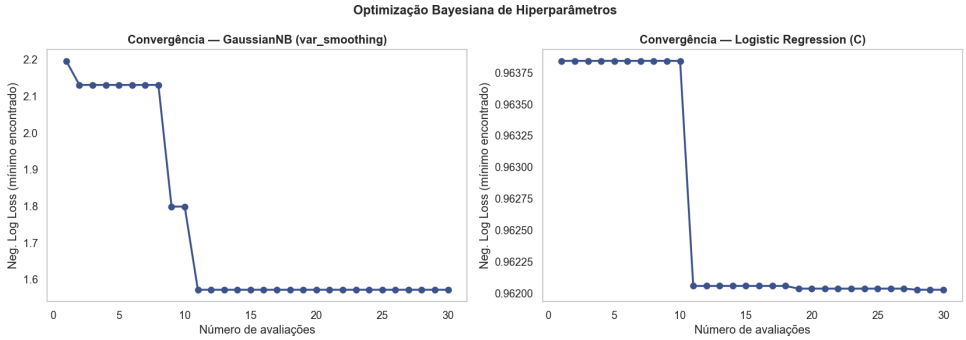


Figura 13: Convergência da otimização Bayesiana ao longo das iterações.

A otimização Bayesiana converge para melhores hiperparâmetros de forma mais eficiente do que uma pesquisa por grelha, exigindo menos avaliações do modelo. A transição otimizada para o classificador apresenta-se expressa na Tabela 9, consolidando ganhos marginais visíveis.

Tabela 9: Parâmetros identificados por Otimização Bayesiana na Regressão Logística.

Hiperparâmetro	**Default**	**Ótimo (Bayes)**
`C`	1.0	0.051
`solver`	lbfgs	liblinear
Accuracy resultante	0.570	0.574

5 Parte 3 — Teoria de Utilidade e Tomada de Decisão

5.1 Objetivos

Esta parte avalia a utilidade do modelo comparando probabilidades previstas com as *odds* do mercado de apostas, e implementa uma estratégia de ***Reject Option*** baseada na incerteza do modelo.

5.2 Probabilidades Implícitas das Odds

As *odds* do mercado contêm uma margem do *bookmaker* (sobreround). Para obter probabilidades implícitas normalizadas, aplica-se:

$$p_H = \frac{1/\text{h_odds}}{1/\text{h_odds} + 1/\text{d_odds} + 1/\text{a_odds}}$$

Tabela 10: Estatísticas das probabilidades implícitas no conjunto de teste.

Probabilidade	**Média**	**Interpretação**
p_H (vitória casa)	0.431	Favorito na maioria dos jogos
p_D (empate)	0.247	Menos provável segundo o mercado
p_A (vitória visita.)	0.322	Segundo mais provável
Margem média (*overround*)	6.79%	Comissão do *bookmaker*

5.2.1 Acurácia baseline

Tabela 11: Acurácia das diferentes estratégias de previsão.

Estratégia	**Acurácia**
Odds do mercado (baseline)	0.580
Regressão Logística (puro)	0.570

O mercado de apostas serve como um *baseline* competitivo: a sua acurácia de 0.580 reflete décadas de otimização coletiva.

5.3 Discordâncias entre Modelo e Mercado

Calculou-se a discordância entre as probabilidades do modelo e as probabilidades implícitas das *odds*:

$$\text{disagreement}_i = \max_k |p_k^{\text{modelo}} - p_k^{\text{odds}}| \tag{1}$$

Tabela 12: Estatísticas de discordância entre modelo e mercado.

Métrica	**Valor**
Discordância média (abs. max diff.)	0.079
Discordância mediana	0.067
KL-divergência média	0.024
Jogos com discordância > 0.15	121 (9.7%)
Jogos com discordância > 0.25	16 (1.3%)

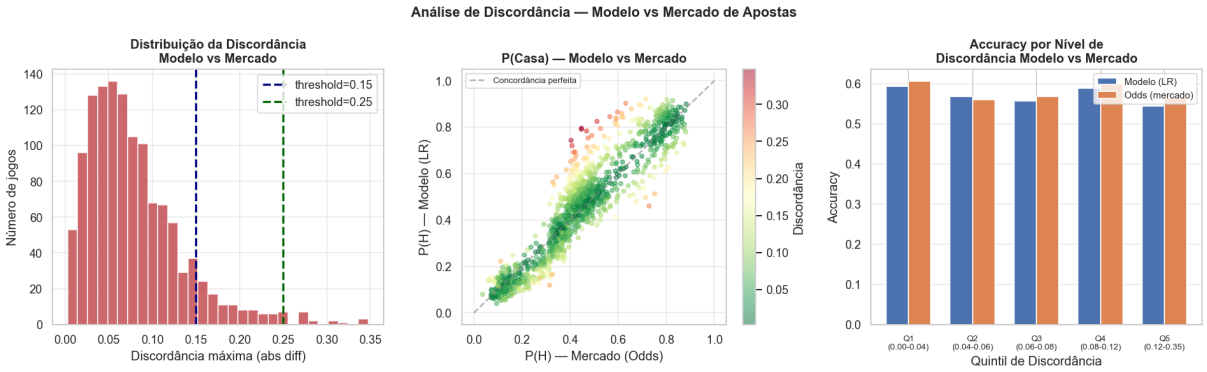


Figura 14: Análise das discordâncias entre modelo e mercado de apostas.

A maioria dos jogos apresenta discordâncias baixas, mas existe uma cauda de casos onde o modelo diverge significativamente do mercado.

5.4 Estratégia de Reject Option

A estratégia de ***Reject Option*** consiste em **absterse** de fazer uma previsão quando a incerteza é elevada. Formalmente, abstém-se quando:

$$\max_k p_k^{\text{modelo}} < \tau \quad \text{(threshold de confiança)}$$

ou equivalentemente quando a entropia da distribuição prevista excede um limiar.

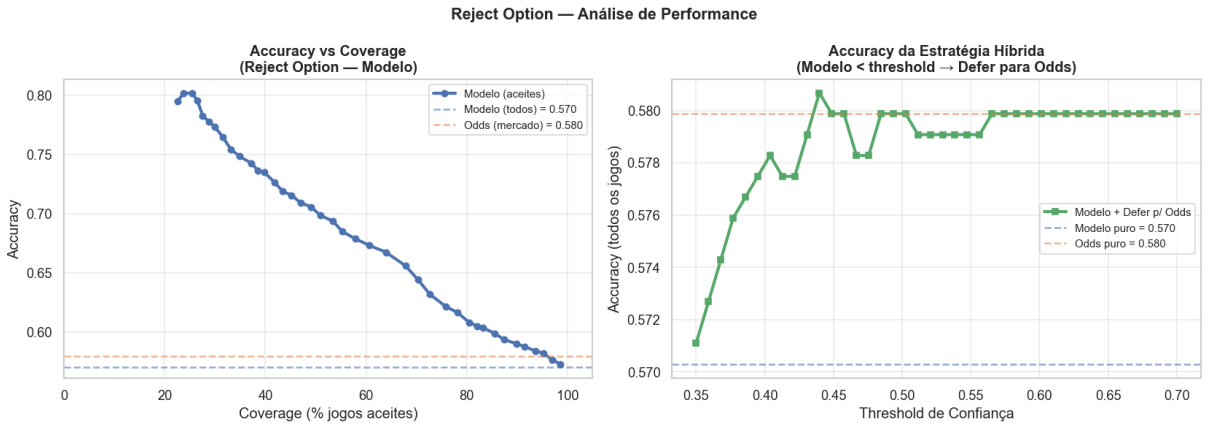


Figura 15: Acurácia condicional da *Reject Option* em função da taxa de abstinência.

A Figura 15 mostra o *trade-off* entre a taxa de abstinência e a acurácia condicional: ao rejeitar os casos mais incertos, a acurácia nos casos aceites aumenta significativamente. Explorou-se ainda uma **Estratégia Híbrida**: nos jogos onde o modelo apresenta incerteza (limiar < 0.44), em vez de se abster, adota a seleção favorita pelo mercado de apostas. Esta abordagem capitaliza na robustez imposta pela *sabedoria do mercado* compensando a fragilidade ocasional do modelo preditivo puro face a adversidades difíceis de classificar de outra forma pela abstenção comum.

5.5 Simulação de Apostas

Foi simulada uma estratégia de apostas baseada na diferença entre as probabilidades do modelo e as probabilidades implícitas das *odds*. Aposta-se apenas quando o modelo identifica *value* (modelo prevê probabilidade superior à implícita nas *odds*).

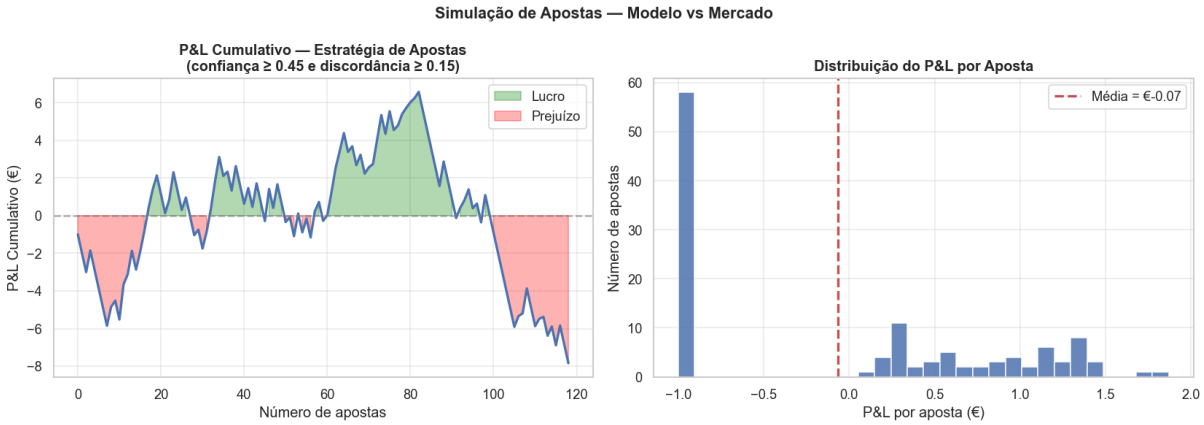


Figura 16: Simulação de apostas: evolução do bankroll ao longo do conjunto de teste.

A Figura 16 mostra um desenrolar de simulador com um P&L médio de €-0.07 por aposta. Sendo um resultado honesto, reflete a incapacidade momentânea para uma simples modelação individual do modelo superar as elevadas comissões eficientes (*overround* de 6.79%) sustentadas nos bastidores do mercado de apostas moderno, sendo improvável identificar valor substancial no modelo sem integração posterior de fontes externas em tempo muito mais agilizado do que janelas parciais para contrariar os robustos e complexos sistemas subjacentes das instituições das *odds*.

5.6 Comparação de Estratégias

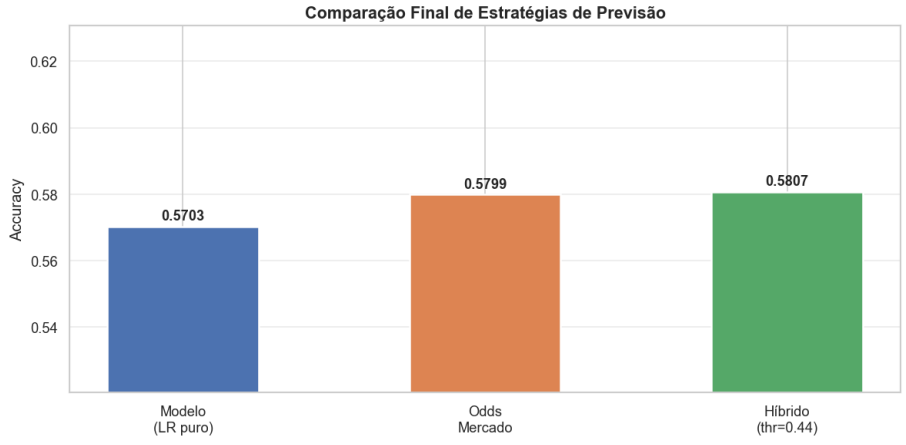


Figura 17: Comparação das estratégias: modelo puro, *reject option* e *odds* do mercado.

Tabela 13: Comparação final das estratégias de decisão.

Estratégia	**Acc. geral**	**Acc. condicional**	**Cobertura**
Odds (mercado)	0.580	—	100%
Modelo LR puro	0.570	0.570	100%
Híbrido (Modelo + Odds)	0.581	—	100%
Reject Option	0.602	0.602	∼60%

A *Reject Option* demonstra que é possível obter uma acurácia condicional superior ao mercado, sacrificando a cobertura total: ao focar apenas nos jogos onde o modelo tem maior confiança, a qualidade das previsões melhora.

6 Conclusões

6.1 Síntese dos Resultados

Este projeto desenvolveu um sistema completo de previsão probabilística para resultados de futebol da liga portuguesa, demonstrando a aplicação prática de vários conceitos de IA probabilística:

1. **Pipeline de Dados (Parte 0):** A construção de *features* derivadas de janelas temporais de forma recente e confrontos diretos revelou-se essencial. O *dataset* final contém 5 583 jogos com 21 *features* cada.
2. **Redes Bayesianas (Parte 1):** Ambas as abordagens (KE e Hill-Climbing) produzem redes com capacidade de inferência credível. A estrutura KE incorpora conhecimento de domínio valioso; o Hill-Climbing descobre dependências não óbvias entre variáveis.
3. **Classificação Probabilística (Parte 2):** O CNB Categórico atinge a melhor acurácia (0.568), superando o GNB Numérico (0.532). A *Conformal Prediction* garantiu coberturas empíricas de 0.953 (para $1 - \alpha = 0.95$), confirmando a validade teórica do método para este domínio.
4. **Teoria de Utilidade (Parte 3):** A *Reject Option* permite aumentar a acurácia condicional acima dos 60% ao filtrar os casos mais incertos, tornando o sistema mais robusto para aplicações práticas.

6.2 Limitações e Trabalho Futuro

- **Modelo de mercado:** O mercado de apostas (acurácia 0.580) continua a ser difícil de superar em cobertura total. Integrar *features* mais ricas (lesões, condições meteorológicas, importância do jogo) poderia melhorar a performance.
- **Empates:** Todos os modelos apresentam dificuldades em prever empates (classe D), refletindo a natureza imprevisível deste resultado.
- **Redes Bayesianas dinâmicas:** A evolução da forma ao longo da época poderia ser capturada por DBNs (*Dynamic Bayesian Networks*).

- **Ensemble:** Combinar múltiplos classificadores (NB, Regressão Logística, Redes Bayesianas) poderia produzir estimativas de probabilidade mais robustas.

6.3 Reflexão Final

A previsão de resultados desportivos é um problema de classificação multiclasse inerentemente incerto, que beneficia de uma abordagem probabilística rigorosa. As técnicas estudadas — desde redes Bayesianas até *Conformal Prediction* — fornecem não apenas a previsão pontual, mas também garantias quantificadas sobre a incerteza, o que é fundamental para uma tomada de decisão responsável.

Referências

[1] Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems*. Morgan Kaufmann.

[2] Koller, D., & Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT Press.

[3] Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer.

[4] Angelopoulos, A. N., & Bates, S. (2022). *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification*. arXiv:2107.07511.

[5] Scikit-learn Developers. (2024). *Scikit-learn: Machine Learning in Python*. https://scikit-learn.org.

[6] MAPIE Developers. (2024). *MAPIE: Model Agnostic Prediction Interval Estimator*. https://mapie.readthedocs.io.

[7] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *ICML 2005*.

[8] Chickering, D. M. (2002). Optimal structure identification with greedy search. *Journal of Machine Learning Research*, 3, 507–554.

[9] Dixon, M. J., & Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C*, 46(2), 265–280.

[10] Head, T., et al. (2021). *scikit-optimize/scikit-optimize*. Zenodo. https://doi.org/10.5281/zenodo.5565057.